BÁO CÁO ĐỒ ÁN: HỆ THỐNG PHÂN TÍCH ĐIỆN NÃO ĐỒ (EEG) ỨNG DỤNG TRÍ TUỆ NHÂN TẠO TRONG PHÁT HIỆN ĐỘNG KINH

MỤC LỤC

1. Tổng Quan Dự Án
2. Cơ Sở Lý Thuyết
3. Dữ Liệu & Tiền Xử Lý
4. Kiến Trúc Mô Hình Deep Learning
5. Huấn Luyện & Tối Ưu
6. Kết Quả Thực Nghiệm
7. Kiến Trúc Hệ Thống Web
8. Giao Diện & Trực Quan Hóa 3D
9. Kết Luận & Hướng Phát Triển
10. Tài Liệu Tham Khảo

1. TỔNG QUAN DỰ ÁN

1.1 Bối cảnh & Động lực

Động kinh (Epilepsy) là một rối loạn thần kinh mãn tính ảnh hưởng đến khoảng **50 triệu người** trên toàn thế giới (theo WHO). Chẩn đoán truyền thống dựa trên việc bác sĩ chuyên khoa thần kinh **đọc thủ công** các bản ghi điện não đồ (EEG) — một quy trình tốn nhiều thời gian, phụ thuộc vào kinh nghiệm chủ quan, và dễ sai sót khi khối lượng dữ liệu lớn.

Mục tiêu: Xây dựng một hệ thống AI tự động phân tích tín hiệu EEG từ file `.edf` (European Data Format), phát hiện các đoạn sóng não bất thường liên quan đến cơn co giật (seizure), và trực quan hóa kết quả trên giao diện web thân thiện với người dùng.

1.2 Phạm vi dự án

Thành phần	Mô tả
Mô hình AI	1D-CNN + BiGRU + Temporal Attention (PyTorch)
Dataset	CHB-MIT Scalp EEG Database (24 bệnh nhân nhi)
Backend API	Python Flask (PyTorch inference) + Node.js (Express)
Frontend	HTML/CSS/JS + Chart.js + Three.js (3D visualization)
Giao thức	MCP Server cho tích hợp AI Chatbot

1.3 Cấu trúc thư mục dự án

```
DU_AN_Y_TE-VIP/
├── python_api.py              # Flask API: load model CNN + inference
├── server.js                  # Node.js Express server (port 3000)
├── mcp-server.js              # MCP protocol server
├── models/
│   ├── best_cnn_model.pth     # Trọng số CNN đã huấn luyện (~880KB)
│   ├── model_metadata.json    # Metadata: threshold, AUC, config
│   └── evaluation_dl_charts.png
├── training/
│   └── train_eeg_ver3.ipynb   # Notebook huấn luyện (Kaggle)
├── public/
│   ├── index.html             # Giao diện chính
│   ├── app.js                 # Logic frontend + 3D visualization
│   ├── styles.css             # Styling (glassmorphism, dark theme)
│   ├── three.min.js           # Three.js r128 (local)
│   └── OrbitControls.js       # Camera controls
└── requirements.txt           # Python dependencies
```

2. CƠ SỞ LÝ THUYẾT

2.1 Điện não đồ (EEG — Electroencephalography)

EEG là phương pháp ghi lại hoạt động điện của não bộ thông qua các điện cực đặt trên da đầu. Tín hiệu EEG phản ánh tổng hợp các điện thế hậu synap (post-synaptic potentials) từ hàng triệu neuron hoạt động đồng bộ.

Các dải tần số EEG cơ bản:

Dải tần	Tần số (Hz)	Trạng thái liên quan
Delta (δ)	0.5 – 4 Hz	Ngủ sâu, hôn mê, có thể bất thường nếu xuất hiện khi tỉnh
Theta (θ)	4 – 8 Hz	Buồn ngủ, thiền định, trẻ em bình thường
Alpha (α)	8 – 13 Hz	Thư giãn, nhắm mắt, nghỉ ngơi tỉnh táo
Beta (β)	13 – 30 Hz	Tập trung, hoạt động nhận thức, lo âu
Gamma (γ)	30 – 50+ Hz	Xử lý cao cấp, ký ức, nhận thức

Biểu hiện EEG trong cơn động kinh:

- Xuất hiện sóng nhọn (spike), sóng nhọn-chậm (spike-wave), hoặc sóng đa nhọn (polyspike)
- Tần số và biên độ thay đổi đột ngột so với nền bình thường
- Có thể lan tỏa từ vùng khu trú (focal) ra toàn bộ vỏ não (generalized)

2.2 Mạng nơ-ron tích chập 1D (1D-CNN)

1D-CNN là biến thể của CNN truyền thống, được thiết kế cho dữ liệu chuỗi thời gian. Thay vì quét kernel 2D trên ảnh, 1D-CNN quét kernel 1D dọc theo trục thời gian.

Công thức tích chập 1D:

$$y[n] = \sum_{k=0}^{K-1} w[k] \cdot x[n+k] + b$$

Trong đó:

- $x[n]$: tín hiệu đầu vào tại vị trí n
- $w[k]$: trọng số kernel (bộ lọc) kích thước K

- b: bias
- $y[n]$: đặc trưng (feature map) đầu ra

Vai trò trong mô hình: 1D-CNN hoạt động như **bộ trích xuất đặc trưng cục bộ** — nhận diện các mẫu sóng ngắn hạn (spike, spike-wave) mà mắt thường khó phát hiện.

Trong kiến trúc của chúng tôi, 3 khối CNN lần lượt:

1. **Block 1** (kernel=15, stride=2): bắt các mẫu tần số thấp (delta, theta)
2. **Block 2** (kernel=7, stride=2): bắt các mẫu tần số trung bình (alpha, beta)
3. **Block 3** (kernel=3): bắt các chi tiết tần số cao (spikes, gamma)

Mỗi block kết hợp `Conv1d → BatchNorm → ReLU → MaxPool → Dropout` để đảm bảo ổn định gradient và giảm overfitting.

2.3 Mạng GRU hai chiều (Bidirectional GRU)

GRU (Gated Recurrent Unit) là dạng cải tiến của RNN, sử dụng 2 cổng (gate) để kiểm soát luồng thông tin:

Cổng Reset (Reset Gate):

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r)$$

Cổng Update (Update Gate):

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z)$$

Trạng thái ẩn ứng viên:

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h)$$

Trạng thái ẩn cuối:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Trong đó:

- σ: hàm sigmoid
- $\odot$: phép nhân element-wise
- r_t: kiểm soát bao nhiêu thông tin quá khứ cần "quên"
- z_t: kiểm soát bao nhiêu thông tin mới cần "cập nhật"

Bidirectional: Chúng tôi sử dụng BiGRU (2 hướng) để model có thể nhìn **cả quá khứ và tương lai** khi phân tích một time step:

$$\overrightarrow{h_t} = \mathrm{GRU}(x_t, \overrightarrow{h_{t-1}}) \quad ; \quad \overleftarrow{h_t} = \mathrm{GRU}(x_t, \overleftarrow{h_{t+1}})$$

$$h_t = [\overrightarrow{h_t}; \overleftarrow{h_t}]$$

Vai trò: BiGRU nắm bắt **ngữ cảnh thời gian dài hạn** — ví dụ, một đoạn sóng spike kéo dài 2-3 giây cần được phân tích trong context trước-sau để xác định có phải seizure hay artifact.

2.4 Cơ chế Temporal Attention

Attention cho phép model **tập trung vào các thời điểm quan trọng** thay vì xử lý đồng đều mọi time step.

Công thức:

$$e_t = \tanh(W_1 h_t + b_1)$$

$$\alpha_t = \frac{\exp(W_2 e_t)}{\sum_{k=1}^{T} \exp(W_2 e_k)}$$

$$c = \sum_{t=1}^{T} \alpha_t \cdot h_t$$

Trong đó:

- h_t: output BiGRU tại thời điểm t
- α_t: attention weight (trọng số chú ý) — cho biết mức độ quan trọng
- c: context vector — tổng hợp thông tin có trọng số

Vai trò: Trong EEG seizure detection, các đoạn bất thường thường chỉ chiếm một phần nhỏ trong cửa sổ 4 giây. Attention học cách **phóng đại tín hiệu bất thường** và **giảm bớt nhiễu nền**, giúp classifier đưa ra quyết định chính xác hơn.

2.5 Focal Loss với Label Smoothing

Vấn đề mất cân bằng dữ liệu: Trong dataset EEG, lớp Normal chiếm ~90% trong khi Seizure chỉ ~10%. Cross-entropy loss truyền thống sẽ bị chi phối bởi lớp đa số.

Focal Loss (Lin et al., 2017) giải quyết bằng cách giảm trọng số cho các mẫu dễ đoán:

$$FL(p_t) = -\alpha_t(1-p_t)^\gamma \log(p_t)$$

Trong đó:

- α_t: trọng số cho từng lớp ($\alpha = 0.75$ cho Seizure — lớp thiểu số)
- $\gamma = 2.0$: **focusing parameter** — $(1-p_t)^\gamma$ tiến về 0 khi mẫu dễ đoán (p_t cao)
- Hiệu quả: model tập trung học từ các mẫu **khó phân biệt** (hard examples)

Label Smoothing ($\epsilon = 0.05$): Thay vì target cứng (0 hoặc 1), chúng tôi dùng target mềm:

$$y_{smooth} = y \times (1-\epsilon) + 0.5 \times \epsilon$$

Điều này ngăn model trở nên **quá tự tin** (overconfident), cải thiện khả năng tổng quát hóa.

2.6 Bộ lọc thông dải Butterworth (Bandpass Filter)

Tín hiệu EEG thô chứa nhiều nhiễu: nhiễu điện lưới 50/60Hz, nhiễu cơ bắp (EMG), nhiễu mắt (EOG). Chúng tôi áp dụng bộ lọc Butterworth bậc 4, dải thông **0.5-40Hz**:

$$H(s) = \frac{1}{\sqrt{1 + \left(\frac{s}{\omega_c}\right)^{2n}}}$$

Trong đó $n = 4$ (bậc lọc), ω_c là tần số cắt.

- **Cắt dưới 0.5Hz:** Loại bỏ drift điện cực (baseline wander)
- **Cắt trên 40Hz:** Loại bỏ nhiễu điện lưới (50/60Hz) và EMG artifact
- **Butterworth:** Được chọn vì đáp ứng tần số phẳng nhất trong dải thông (maximally flat)

Sử dụng `sosfiltfilt` (zero-phase filtering) để không gây méo pha tín hiệu — rất quan trọng trong phân tích EEG.

3. DỮ LIỆU & TIỀN XỬ LÝ

3.1 Dataset: CHB-MIT Scalp EEG Database

Thuộc tính	Giá trị
Nguồn	PhysioNet / Children's Hospital Boston
Đối tượng	24 bệnh nhân nhi (5 nam, 17 nữ, 2 chưa xác định)
Tần số lấy mẫu	256 Hz
Số kênh	23 kênh EEG (hệ thống 10-20 quốc tế)
Tổng thời lượng	~983 giờ ghi liên tục
Số cơn Seizure	198 cơn (có ghi chú chính xác thời điểm bắt đầu/kết thúc)
Định dạng	EDF (European Data Format)

3.2 Quy trình tiền xử lý dữ liệu

File EDF (.edf)
Đọc tín hiệu EEG (pyedflib)
Lọc kênh EEG (loại ECG, VNS, blank)
Padding/Truncate → 23 kênh cố định
Bandpass Filter 0.5-40Hz (Butterworth bậc 4)
Cắt cửa sổ 4 giây (1024 mẫu)
Seizure?
Có
Không

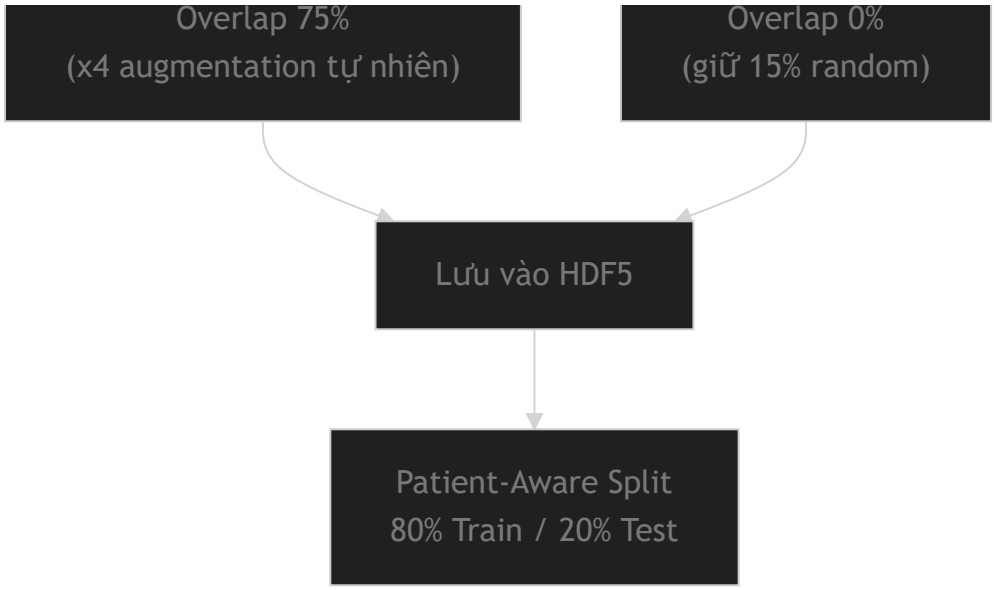

3.3 Chiến lược xử lý mất cân bằng lớp

Kỹ thuật	Chi tiết
Asymmetric Overlap	Seizure: overlap 75% (x4) / Normal: overlap 0%
Normal Subsampling	Chỉ giữ 15% cửa sổ Normal (random)
Focal Loss	α=0.75 cho Seizure, γ=2.0
Online Augmentation	Gaussian noise, amplitude scaling, channel masking, time masking

3.4 Patient-Aware Data Split

> **Important**
>
> **Tại sao không dùng random split?** Random split có thể đặt các cửa sổ từ cùng một bệnh nhân vào cả train và test, gây **data leakage**. Model sẽ học đặc điểm riêng của bệnh nhân thay vì đặc trưng seizure phổ quát.

Phương pháp: Chia theo **bệnh nhân**, không theo cửa sổ:

- **Train:** 19 bệnh nhân (chb01-06, 09-10, 12-14, 16-19, 21-24)
- **Test:** 5 bệnh nhân (chb07, 08, 11, 15, 20)

Đảm bảo: **không có dữ liệu nào** của bệnh nhân test xuất hiện trong train set.

4. KIẾN TRÚC MÔ HÌNH DEEP LEARNING

4.1 Tổng quan kiến trúc

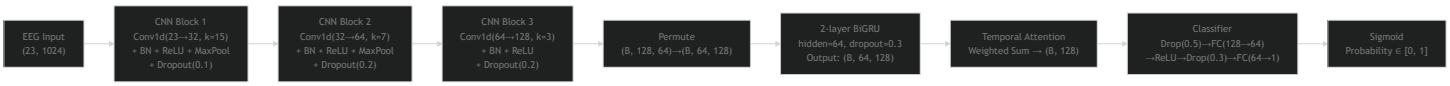

4.2 Chi tiết từng thành phần

4.2.1 CNN Feature Extractor

Layer	Input Shape	Kernel	Stride	Output Shape	Vai trò
Conv1d Block 1	(23, 1024)	15	2	(32, 256)	Bắt mẫu sóng chậm (delta, theta)
Conv1d Block 2	(32, 256)	7	2	(64, 64)	Bắt mẫu sóng trung bình (alpha, beta)
Conv1d Block 3	(64, 64)	3	1	(128, 64)	Bắt chi tiết (spikes, gamma)

Mỗi block sử dụng **Spatial Dropout** sau đó — một kỹ thuật regularization hiệu quả cho time series, giúp giảm **co-adaptation** giữa các feature map liền kề.

4.2.2 BiGRU Temporal Encoder

```
Input:  (Batch, 64, 128)   ← 64 time steps, 128 features/step
GRU:    2 layers, hidden=64, bidirectional=True, dropout=0.3
Output: (Batch, 64, 128)   ← 64 time steps, 128 = 64×2 (forward + backward)
```

- **2 layers** (tăng từ 1 layer ở phiên bản trước): tăng capacity biểu diễn
- **Dropout 0.3** giữa 2 GRU layers: ngăn overfitting giữa các tầng recurrent
- **Bidirectional**: nhìn cả 2 hướng thời gian

4.2.3 Temporal Attention Layer

```
Attention = Linear(128 → 64) → Tanh → Linear(64 → 1)
Weights   = Softmax(scores) ∈ ℝ^(batch, 64)
Context   = Σ(weights × gru_output) ∈ ℝ^(batch, 128)
```

Attention weights trực quan hóa **phần nào** của cửa sổ 4 giây mà model quan tâm nhất. Vùng seizure thường có attention weight cao.

4.3 Tổng số tham số

Component	Parameters
CNN Blocks (1+2+3)	~85,000
BiGRU (2 layers)	~99,000
Attention	~4,200
Classifier	~8,400
Tổng	**~196,600**

Model nhỏ gọn (~880KB), phù hợp triển khai trên edge devices.

5. HUẤN LUYỆN & TỐI ƯU

5.1 Cấu hình huấn luyện

Hyperparameter	Giá trị	Lý do
Optimizer	**AdamW**	Tách biệt weight decay khỏi gradient, hiệu quả hơn Adam
Learning Rate (max)	**3×10^{-4}**	Thấp hơn default (1e-3) để giảm dao động
Weight Decay (L2)	**1×10^{-2}**	Mạnh hơn default (1e-4) để chống overfitting

Hyperparameter	Giá trị	Lý do
Scheduler	**CosineAnnealingWarmRestarts**	LR giảm rồi tăng lại theo chu kỳ T_0=10, T_mult=2
Epochs	**50** (early stop)	Dừng sớm nếu Val F1 không cải thiện sau 10 epochs
Batch Size	**256**	Tối ưu cho dual T4 GPU trên Kaggle
Mixed Precision	**AMP (FP16)**	Giảm 50% memory GPU, tăng tốc 20-30%
Label Smoothing	**0.05**	Ngăn model overconfident
Gradient Clipping	**max_norm=1.0**	Ổn định gradient cho RNN layers

5.2 Online Data Augmentation (GPU-side)

Augmentation	Xác suất	Chi tiết
Gaussian Noise	50%	σ=0.01, mô phỏng nhiễu sensor
Amplitude Scaling	50%	×0.8-1.2, mô phỏng biến thiên tín hiệu
Channel Masking	30%	Zero-out 1-2 kênh random, chống co-adaptation
Time Masking	30%	Zero-out 10% thời gian, tăng robustness

Tất cả augmentation được thực hiện **trên GPU** (bằng tensor operations) thay vì CPU, giảm nghẽn data pipeline.

5.3 Early Stopping

- **Metric giám sát:** Validation F1-Score
- **Patience:** 10 epochs
- **Kết quả:** Model dừng tại epoch 25/50 (tiết kiệm 50% thời gian train)
- **Best epoch:** 14 (Val F1 = 0.481)

6. KẾT QUẢ THỰC NGHIỆM

6.1 Metrics tổng quan

Metric	Giá trị
ROC-AUC	**0.839**
PR-AUC (Average Precision)	**0.529**
Best Validation F1	**0.481**
Best Threshold	**0.40**

6.2 Biểu đồ đánh giá

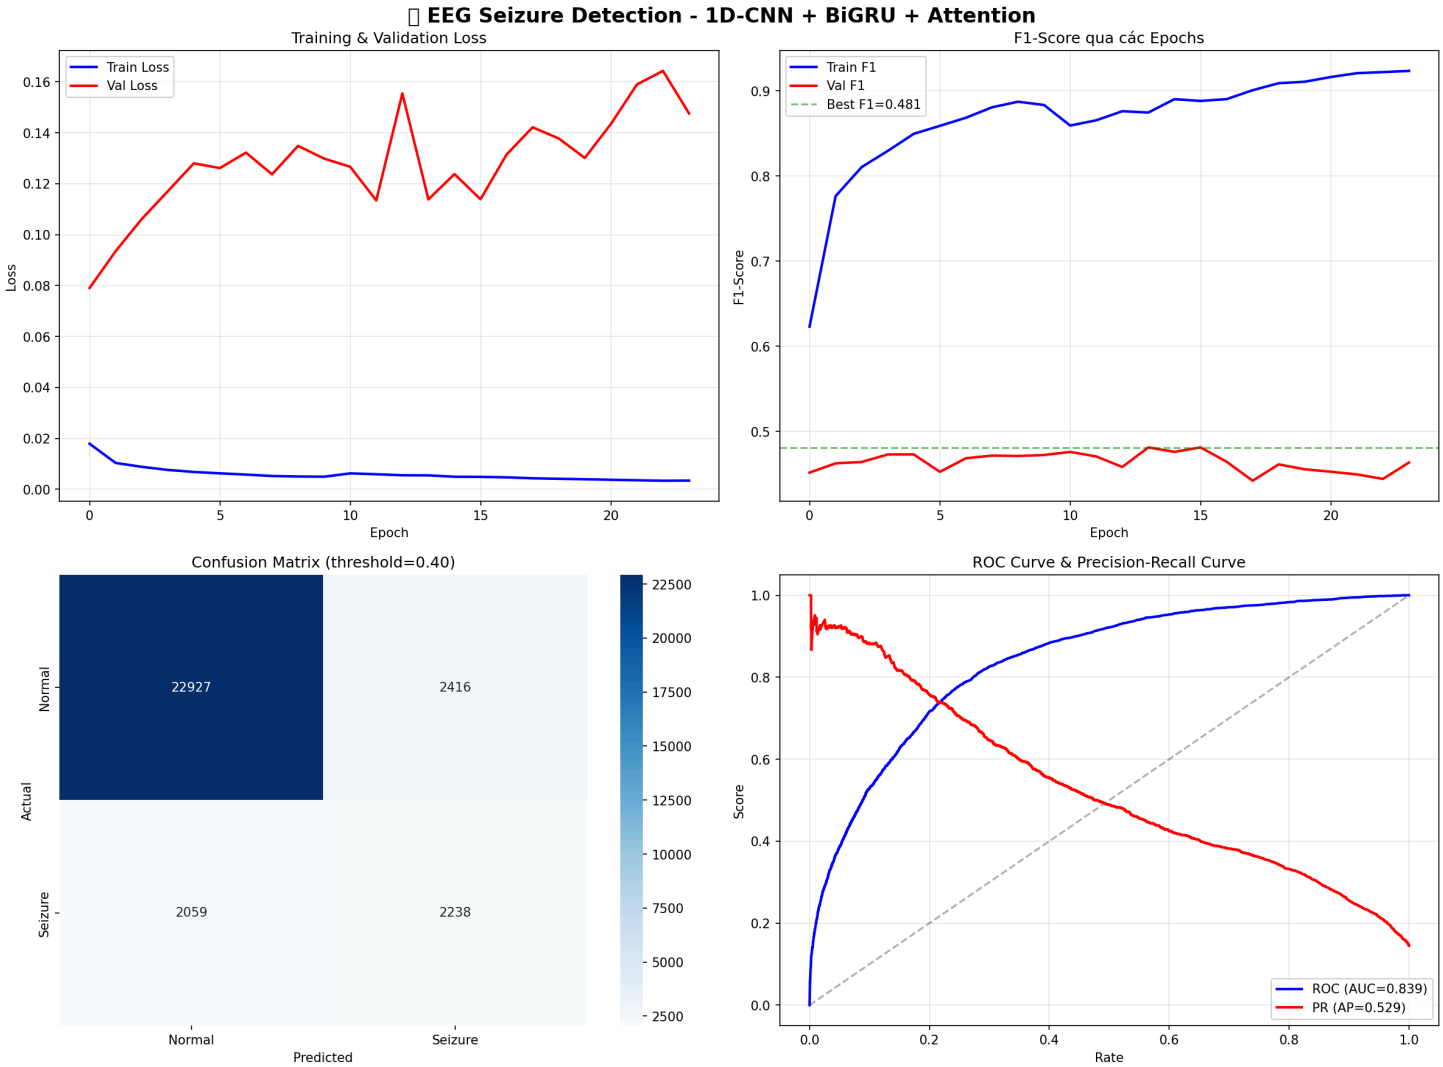

6.3 Confusion Matrix (threshold = 0.40)

	Predicted Normal	Predicted Seizure
Actual Normal	22,927 (TN)	2,416 (FP)
Actual Seizure	2,059 (FN)	2,238 (TP)

- **Sensitivity (Recall):** 2,238 / (2,238 + 2,059) = **52.1%**
- **Specificity:** 22,927 / (22,927 + 2,416) = **90.5%**
- **Precision:** 2,238 / (2,238 + 2,416) = **48.1%**

6.4 Phân tích kết quả

> **Note**
>
> **ROC-AUC = 0.839** cho thấy model có khả năng phân biệt seizure/normal **tốt** ở mức tổng thể. PR-AUC = 0.529 trên dataset cực kỳ mất cân bằng (tỉ lệ seizure ~15%) là kết quả khả quan.

Điểm mạnh:

- Model tổng quát hóa tốt trên **bệnh nhân chưa từng thấy** (patient-aware split)
- Specificity cao (90.5%) — ít báo động giả cho trường hợp bình thường
- Kích thước nhỏ (~880KB) — phù hợp triển khai trên edge devices

Hạn chế & Hướng cải thiện:

- Sensitivity 52.1% còn cần cải thiện — có thể bỏ sót ~48% seizure
- Có thể thử:
  - Kiến trúc Transformer (self-attention thay GRU)
  - Tăng dữ liệu bằng synthetic seizure generation (GANs)
  - Multi-scale CNN (song song nhiều kernel size)
  - Cross-patient transfer learning

7. KIẾN TRÚC HỆ THỐNG WEB

7.1 Kiến trúc tổng thể

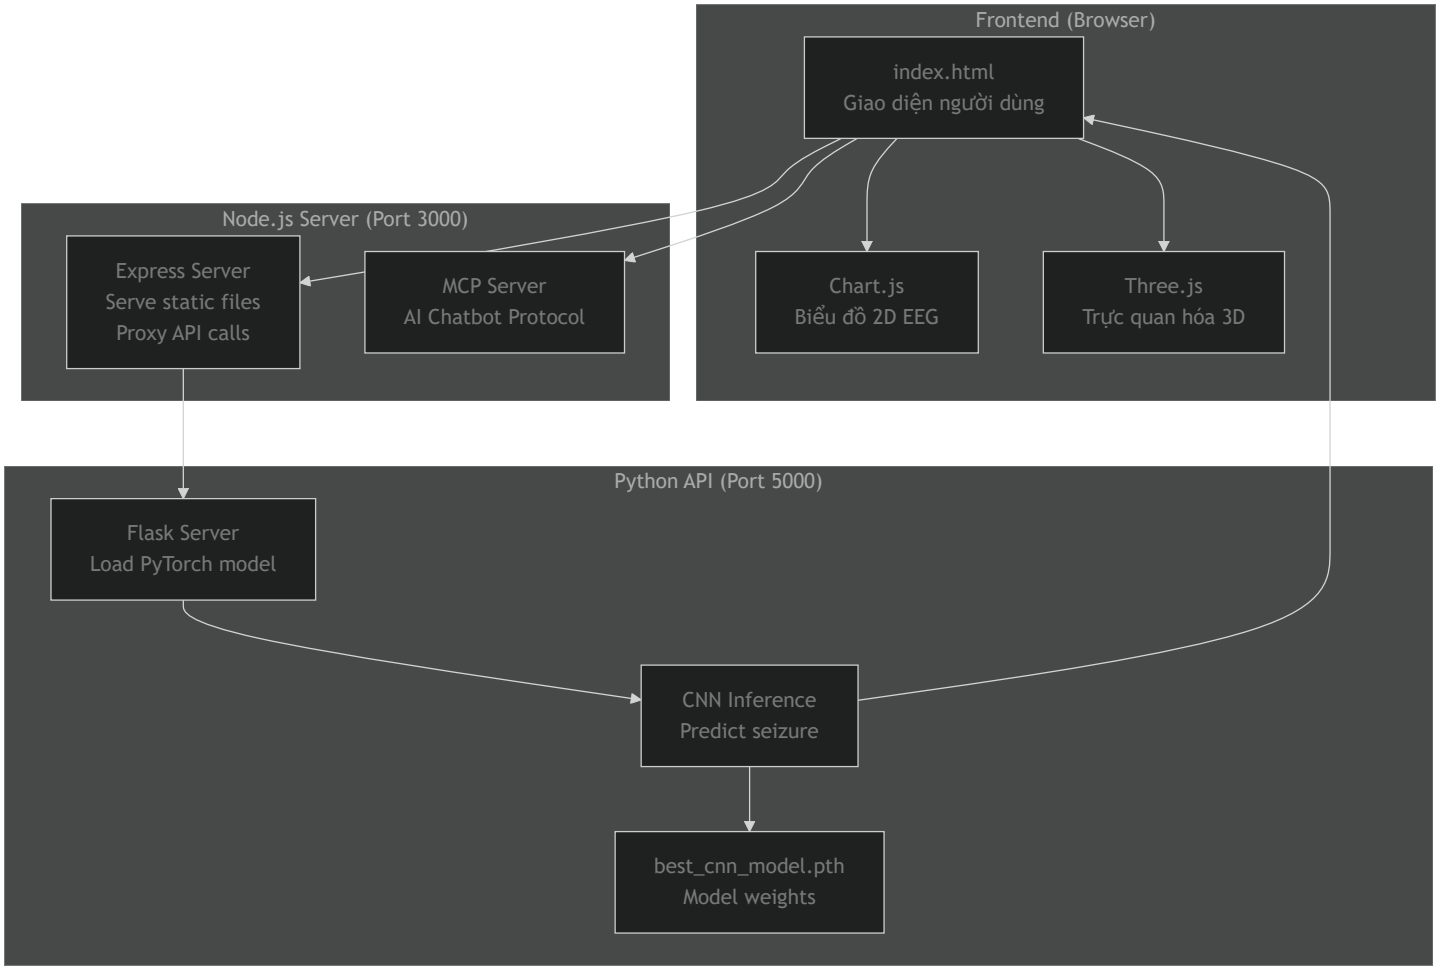

7.2 Luồng xử lý khi upload file EDF

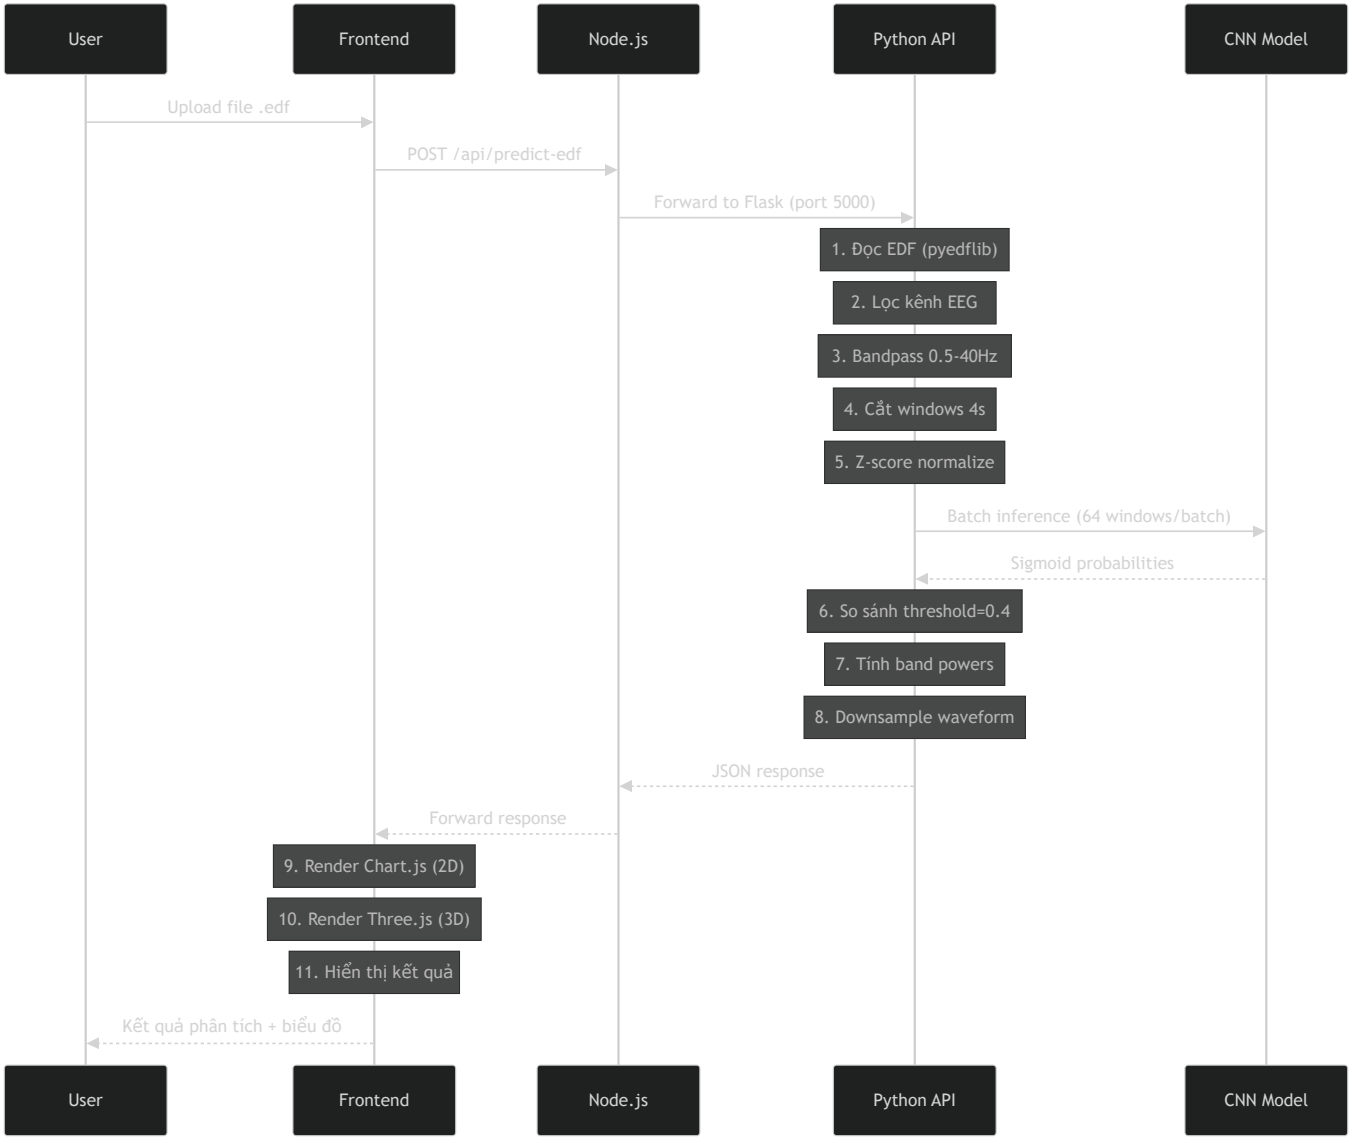

7.3 API Endpoints

Endpoint	Method	Mô tả
`/api/predict-edf`	POST	Upload file .edf → trả về kết quả phân tích
`/api/model-info`	GET	Thông tin model (architecture, AUC, threshold)
`/health`	GET	Health check
`/api/analyze-image`	POST	Phân tích ảnh EEG bằng GPT-4 Vision
MCP Protocol	stdio	Tích hợp AI chatbot tư vấn

8. GIAO DIỆN & TRỰC QUAN HÓA 3D

8.1 Thiết kế giao diện

Giao diện được thiết kế theo phong cách **Glassmorphism + Dark Theme**, tối ưu cho môi trường y tế:

- **Dark theme** giảm mỏi mắt khi xem lâu
- **Glassmorphism** tạo chiều sâu thị giác
- **Color coding** rõ ràng: xanh = bình thường, đỏ = bất thường
- **4 tabs:** Upload & Phân Tích | Biểu Đồ | Chatbot Tư Vấn | MCP Server

8.2 Biểu đồ 2D (Chart.js)

1. **EEG Waveform:** Multi-channel với offset, highlight vùng bất thường (đỏ)
2. **Frequency Bands:** Radar chart phân bố công suất delta/theta/alpha/beta/gamma
3. **Anomaly Timeline:** Xác suất bất thường theo thời gian với threshold line
4. **Band Power Comparison:** Bar chart so sánh công suất giữa các dải tần

8.3 Trực quan hóa 3D (Three.js) — Premium

Sử dụng Three.js r128 để render EEG trong không gian 3D:

Tính năng	Mô tả
** Star Field**	2000 ngôi sao nền tạo cảm giác immersive
** Particle System**	300 hạt phát sáng bay lơ lửng (bật/tắt)
** Gradient Color**	Màu thay đổi theo biên độ (low→high = dim→bright)
** Glow Spheres**	Vùng bất thường: quả cầu phát sáng + nhấp nháy
** Accent Lights**	3 đèn màu (tím, xanh, cyan) tạo dramatic effect
** Camera Fly-in**	Camera bay vào mượt mà khi data load
** 5 View Presets**	Phối cảnh, Trên, Bên, Trước, Cinematic
** Surface Mesh**	Bề mặt kết nối giữa các kênh (toggle)
** Info Overlay**	Số kênh, thời lượng, số vùng bất thường

Trục tọa độ:

- X: Thời gian (0 → duration)
- Y: Biên độ tín hiệu (z-score normalized)
- Z: Kênh EEG (spacing 6 units)

9. KẾT LUẬN & HƯỚNG PHÁT TRIỂN

9.1 Kết luận

Đồ án đã xây dựng thành công một hệ thống end-to-end phân tích EEG tự động:

1. **Mô hình deep learning** (1D-CNN + BiGRU + Temporal Attention) đạt ROC-AUC **0.839** trên dataset CHB-MIT với patient-aware evaluation
2. **Hệ thống web** hoàn chỉnh cho phép upload file EDF, phân tích tự động, và trực quan hóa kết quả bằng biểu đồ 2D và 3D
3. **Tích hợp AI chatbot** (MCP Server + GPT-4 Vision) hỗ trợ bác sĩ diễn giải kết quả

9.2 Hướng phát triển

Hướng	Chi tiết
Cải thiện model	Thử Transformer (EEGNet-Transformer), Self-supervised pretraining
Tăng dữ liệu	Thu thập EEG từ bệnh viện Việt Nam, synthetic augmentation (DCGAN)
Real-time	Streaming EEG từ thiết bị → inference qua WebSocket
Mobile	React Native / Flutter app cho bác sĩ
Certification	Tiến tới chứng nhận FDA/CE cho ứng dụng y tế

10. TÀI LIỆU THAM KHẢO

1. **CHB-MIT Scalp EEG Database** — Shoeb, A.H. (2009). "Application of Machine Learning to Epileptic Seizure Onset Detection and Treatment." PhD Thesis, MIT.
2. **Focal Loss** — Lin, T.Y. et al. (2017). "Focal Loss for Dense Object Detection." IEEE ICCV.
3. **GRU** — Cho, K. et al. (2014). "Learning Phrase Representations using RNN Encoder-Decoder." EMNLP.

4. **Attention Mechanism** — Bahdanau, D. et al. (2015). "Neural Machine Translation by Jointly Learning to Align and Translate." ICLR.
5. **Batch Normalization** — Ioffe, S. & Szegedy, C. (2015). "Batch Normalization: Accelerating Deep Network Training." ICML.
6. **AdamW** — Loshchilov, I. & Hutter, F. (2019). "Decoupled Weight Decay Regularization." ICLR.
7. **Mixed Precision Training** — Micikevicius, P. et al. (2018). "Mixed Precision Training." ICLR.
8. **Three.js** — https://threejs.org/ — WebGL 3D visualization library.
9. **CHB-MIT PhysioNet** — https://physionet.org/content/chbmit/1.0.0/
10. **MNE-Python** — Gramfort, A. et al. (2013). "MEG and EEG data analysis with MNE-Python." Frontiers in Neuroscience.

> **Đồ án thực hiện bởi:** Nhóm dự án EEG Brain Analysis
> **Công nghệ:** Python (PyTorch, Flask) | Node.js (Express) | Three.js | Chart.js
> **Ngày hoàn thành:** Tháng 4/2026